

Singulærverdidekomposisjon (SVD)

Andrey Chesnokov

28. september 2025

Oversikt

- 1 Innledning
- 2 Definisjon
- 3 Geometrisk tolkning
- 4 Egenskaper av SVD
- 5 Eksempel: Beregning av SVD
- 6 Anvendelser
- 7 Eksempel: Beste 1D-delrom

Motivasjon

- SVD er et fundamentalt verktøy i numerisk lineær algebra.
- Har mange anvendelser: data-kompresjon, PCA, numerisk stabilitet.
- Det fins stabile algoritmer for å regne ut SVD

Videolenker om SVD

- 1976 celluloid video: “Singular Value Decomposition explained”
- Cleve Moler: “The SVD Saves the Universe”

Teorem 12.11 (Eksistens av SVD)

Teorem

For enhver $m \times n$ matrise A finnes ortogonale matriser $U \in \mathbb{R}^{m \times m}$ og $V \in \mathbb{R}^{n \times n}$, og en diagonal matrise $\Sigma \in \mathbb{R}^{m \times n}$ med ikke-negative elementer slik at

$$A = U\Sigma V^T.$$

Mer detaljert skisse av bevis (Teorem 12.11)

- $A^T A$ er symmetrisk og positiv semidefinit: for alle x ,
 $x^T A^T A x = \|Ax\|^2 \geq 0$.
- Dermed kan vi diagonaliseres: $A^T A = V \Lambda V^T$.
- Egenverdiene $\lambda_i \geq 0$. Definer $\sigma_i = \sqrt{\lambda_i}$.
- For hver $\sigma_i > 0$, definer $u_i = \frac{1}{\sigma_i} A v_i$.
- Disse u_i er ortogonale og kan normaliseres til en ortogonal basis.
- Da kan vi skrive $A = U \Sigma V^T$.

Geometri av SVD

- A avbilder enhetskulen i $\mathbb{R}^n$ til et ellipsoide i $\mathbb{R}^m$.
- Semi-aksene har lengder gitt av de singulære verdiene σ_i .
- Retningene er gitt av de venstre singulære vektorene (kolonnene i U).
- Applet som viser SVDs virkningsmåte:
https://andreyac.folk.ntnu.no/svd_complete.html

Egenskaper (Seksjon 12.4.1)

- 1 Singulære verdier er kvadratrøtter av egenverdier til $A^T A$.
- 2 $\text{rank}(A) =$ antall ikke-null singulære verdier.
- 3 $\|A\|_2 = \sigma_1$ (største singulære verdi).
- 4 $\|A\|_F^2 = \sum_i \sigma_i^2$ (Frobenius-normen).
- 5 Kondisjonstall: $\kappa(A) = \frac{\sigma_1}{\sigma_r}$.

Skisser av bevis for egenskapene

- (1) $A^T A v_i = \lambda_i v_i$, $\sigma_i = \sqrt{\lambda_i}$.
- (2) Hvis $\sigma_i = 0$, da $A v_i = 0$; ellers gir bidrag til rangen.
- (3) $\|A\|_2 = \max_{\|x\|=1} \|Ax\| = \sigma_1$.
- (4) $\|A\|_F^2 = \text{trace}(A^T A) = \sum_i \sigma_i^2$.
- (5) se neste slide.

Kondisjonstall i 2-norm

For en invertibel matrise A defineres kondisjonstallet i 2-norm som

$$\kappa(A) = \|A\|_2 \cdot \|A^{-1}\|_2.$$

Fra SVD $A = U\Sigma V^T$:


- $\|A\|_2 = \sigma_1$ (største singulærverdi).
- $\|A^{-1}\|_2 = 1/\sigma_r$ (minste singulærverdi).

$$\Rightarrow \kappa(A) = \frac{\sigma_1}{\sigma_r}.$$

Intuisjon:

- σ_1 : maksimal strekking av en vektor.
- σ_r : minimal kompresjon av en vektor.
- Hvis $\sigma_r \ll \sigma_1$, kan små endringer i b gi store endringer i løsningen x .

Kondisjonsellipse



(Sirkel transformeres til ellipse: forholdet mellom akser = $\kappa(A)$)

Egenskap 6: Rang-1-sum

Resultat

Hver matrise kan skrives som

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T$$

der $r = \text{rank}(A)$.

Skisse av bevis for rang-1-sum

- Fra $A = U\Sigma V^T$ kan vi skrive

$$A = \sum_{i=1}^n \sigma_i u_i v_i^T.$$

- Hvert ledd $\sigma_i u_i v_i^T$ er en matrise av rang 1.
- Hvis $\sigma_i = 0$ for $i > r$, bidraget er null. Dermed får vi sum over r ikke-null ledd.
- Dette viser hvordan A bygges opp fra r rang-1-matriser.

Inverse matriser via SVD

La $A \in \mathbb{R}^{n \times n}$ ha SVD

$$A = U\Sigma V^T,$$

der $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$.

- Hvis alle $\sigma_i > 0$, er A invertibel.
- Inversen kan uttrykkes direkte som

$$A^{-1} = V\Sigma^{-1}U^T,$$

hvor $\Sigma^{-1} = \text{diag}(1/\sigma_1, \dots, 1/\sigma_n)$.

- Denne fremgangsmåten er numerisk stabil, spesielt når σ_i varierer mye i størrelse.

Pseudoinvers via SVD

Hvis noen singulære verdier $\sigma_i = 0$, finnes ikke A^{-1} .
Da bruker vi i stedet **Moore–Penrose pseudoinvers**:

$$A^+ = V\Sigma^+U^T,$$

hvor Σ^+ har $1/\sigma_i$ for $\sigma_i \neq 0$, og 0 ellers.

- Vanlig bruk: å beregne en **best fit**-løsning (minste kvadraters tilnærming) når et system $Ax = b$ ikke har en eksakt løsning.
- Også nyttig for å finne løsningen med **minste (euklidske) norm** når systemet har mange løsninger.

Innledning til eksempel

Vi beregner SVD for en 3×2 matrise A . Vi arbeider med $A^T A$ (kompakt 2×2 -versjon), som fanger opp alle nødvendige relasjoner i kolonnerommet.

Steg 1: Matrisen A

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$$

Vi ønsker å finne U, Σ, V slik at $A = U\Sigma V^T$.

Steg 2: Beregn $A^T A$

Multipliser A^T og A :

$$A^T A = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

Steg 3: Finn egenverdier

Karakteristisk polynom:

$$\det\left(\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} - \lambda I\right) = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3$$

$$\Rightarrow \lambda_1 = 3, \quad \lambda_2 = 1$$

Steg 4: Singulære verdier

$$\sigma_1 = \sqrt{3}, \quad \sigma_2 = 1$$

Disse bestemmer lengdene på ellipsoide-aksene.

Steg 5: Høyre singulære vektorer (V)

Løs $A^T A v = \lambda v$.

- For $\lambda_1 = 3$: $v_1 = \frac{1}{\sqrt{2}}(1, 1)^T$
- For $\lambda_2 = 1$: $v_2 = \frac{1}{\sqrt{2}}(1, -1)^T$

Dermed

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

Steg 6: Venstre singulære vektorer (U)

Beregn $u_i = \frac{1}{\sigma_i} A v_i$.

- $u_1 = \frac{1}{\sqrt{3}} A v_1 = \frac{1}{\sqrt{6}} (2, 1, 1)^T$
- $u_2 = \frac{1}{1} A v_2 = \frac{1}{\sqrt{2}} (0, 1, -1)^T$

Vi utvider med $u_3 = \frac{1}{\sqrt{3}} (1, -1, 1)^T$ for å få en ortogonal basis i $\mathbb{R}^3$.

Steg 7: Matrisen U

Samle vektorene:

$$U = \begin{bmatrix} \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{bmatrix}$$

Steg 8: Σ og fullstendig dekomposisjon

$$\Sigma = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$$

Dermed

$$A = U\Sigma V^T$$

Oppsummering av eksempelet

Vi har funnet SVD av

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$$

med

$$U = \begin{bmatrix} \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

Dermed gjelder

$$A = U\Sigma V^T$$

Intuisjon: V^T roterer koordinater, Σ strekker i aksene, og U roterer resultatet til slutt.

Lav-rang-approximasjon

Teorem (Eckart–Young)

Den beste rang- k approximasjon av A i 2-normen eller Frobenius-normen er

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T.$$

- Gir optimal dimensjonsreduksjon.
- Brukes i data-kompresjon og PCA.

Anvendelser av SVD

- PCA (Principal Component Analysis).
- Data-kompresjon (tekst, bilde, video).
- Støydemping i signalbehandling.
- Numerisk stabilitet i minste kvadraters problemer.

Hvorfor er $(uu^T)x_j$ en projeksjon på $\text{span}\{u\}$?

La u være en enhetsvektor og $P = uu^T$.

- For alle x : $Px = (u^T x)u \in \text{span}\{u\}$.
- P er symmetrisk $\Rightarrow$ ortogonal projeksjon.

- **Minimeringsegenskaper:**

Blant alle vektorer på linjen $\{\alpha u\}$ er $(u^T x)u$ den som minimerer avstanden til x :

$$\|x - \alpha u\|^2 = \|x\|^2 - 2\alpha(u^T x) + \alpha^2\|u\|^2.$$

Derivert gir $-2(u^T x) + 2\alpha = 0 \Rightarrow \alpha = u^T x$.

Dermed er Px nærmest x i euklidisk norm—definisjonen av projeksjon.

Data og mål

Punkter: $[3, 2]^T, [2, 4]^T, [-2, -1]^T, [-3, -5]^T$.

Mål: Finn linjen (dvs en-dimensjonal underrom) som minimerer $\sum_j \|x_j - (uu^T)x_j\|^2$.

Med SVD $A = U\Sigma V^T$ er beste linje $\text{span}\{u_1\}$.

SVD-resultater

For $A = \begin{bmatrix} 3 & 2 & -2 & -3 \\ 2 & 4 & -1 & -5 \end{bmatrix}$:

$$\sigma_1 \approx 8.280881, \sigma_2 \approx 1.851217,$$

$$u_1 \approx (-0.589, -0.808)^T.$$

Rang-1-tilnærming: $A_1 = \sigma_1 u_1 v_1^T$.

Bevart energi: $\approx 95.2\%$, restfeil $\sigma_2^2 \approx 3.427$.

Projeksjoner

$$[3, 2]^T \mapsto (1.991, 2.735)^T$$

$$[2, 4]^T \mapsto (2.596, 3.566)^T$$

$$[-2, -1]^T \mapsto (-1.169, -1.605)^T$$

$$[-3, -5]^T \mapsto (-3.419, -4.695)^T$$

Plot: vektorer, projeksjoner og $\text{span}\{u_1\}$

