

Kvalitetskontroll basert på multippel t-test

Jon Glenn Gjevestad

9. februar 2012

Sammendrag

Det er i teorien for minste kvadraters metode (MKM) vanlig å anta at observasjonsfeilene er tilfeldige og normalfordelte. Dersom dette er tilfellet vil MKM-estimatoren gi optimal løsning i form av minimum feilkvadratsum.

Men dersom det skulle vise seg å være en grovfeil blant observasjonene vil MKM mer eller mindre fordele denne grovfeilen på alle restfeilene. Dette gjør at grovfeilen blir svært vanskelig å detektere, samt at forutsetningen om at observasjonsfeilene er normalfordelte ikke lenger er gyldig.

Det er derfor utviklet metoder som kan detektere og identifisere grove feil i observasjonsmateriale før man gjør en utjevningsberegning. Noen slike metoder er f.eks:

1. Datasnooping (Baarda)
2. Tau-test
3. Multippel t-test

Av disse metodene er det Multippel t-test som i dette notatet er valgt som basis for kvalitetskontroll av observasjoner.

Kvalitetskontroll av observasjoner foregår normalt i tre trinn:

1. Deteksjon (Test av feilkvadratsum)
2. Identifikasjon (Multippel t-test)
3. Adapsjon (Observasjon med størst-verdi fjernes fra systemet)

1 Test av feilkvadratsum

Denne testen er en av flere såkalte global-tester som behandler hele systemet under ett. Denne testen vil gi en indikasjon på om det er tvang i systemet og brukes ofte for *deteksjon* av grovfeil.

Hypotesene for test av feilkvadratsum er:

$$H_0 : \hat{\sigma}_0^2 = \sigma_0^2$$

$$H_1 : \hat{\sigma}_0^2 \neq \sigma_0^2$$

, der σ_0 er a priori standardavvik på vektsenheten og $\hat{\sigma}_0$ er a posteriori standardavvik på vektsenheten.

Teststørrelsen i dette tilfellet er:

$$z = \frac{v^T P v}{\sigma_0^2} = \frac{\hat{\sigma}_0^2}{\sigma_0^2} (n - e) \sim \chi_{(n-e)}^2 \quad (1)$$

, der P er vektmatrisen og v er restfeilene. Videre er n antall observasjoner og e antall ukjente.

Dersom $\chi_{(n-e, \alpha/2)}^2 < z < \chi_{(n-e, 1-\alpha/2)}^2$ aksepteres H_0 , og $\hat{\sigma}_0^2$ kan ikke påstås å være forskjellig fra σ_0^2 .

Ofte er det aktuelt å kunne sammenligne feilkvadratsummer, f.eks. sammenligne friutjevning mot tvangsutjevning.

Hypotesene for test av endring i feilkvadratsum er:

$$H_0 : v^T P v_2 = v^T P v_1$$

$$H_1 : v^T P v_2 > v^T P v_1$$

* Ant. frihetsgrader korrigert mars2014

Teststørrelsen i dette tilfellet er:

$$f = \frac{(v^T P v_2 - v^T P v_1)/(\nu_2 - \nu_1)}{v^T P v_1 / \nu_1} \sim F_{\nu_2 - \nu_1, \nu_1} \quad (2)$$

, $\nu_1 = n_1 - e_1$ og $\nu_2 = n_2 - e_2$ er antall frihetsgrader.

Dersom $f < F_{(\nu_2 - \nu_1, \nu_1, \alpha)}$ aksepteres H_0 , og $v^T P v_2$ kan ikke påstås være forskjellig fra $v^T P v_1$.

2 Estimering av grovfeil

Grovfeilen estimeres normalt sammen med de ukjente ved å legge til en ny kolonne i designmatrisen med en ener for observasjonen som skal testes for grovfeil, og null ellers.

$$A_i = (A \quad e_i) \quad (3)$$

Indeks i betegner her at man skal teste for grovfeil i observasjon nr. i . F.eks. er $e_1^T = (1 \ 0 \ 0 \ \dots \ 0)$ ved estimering av grovfeil i observasjon nr. 1.

$$A_1 = \begin{pmatrix} - & - & \cdot & 1 \\ - & - & \cdot & 0 \\ - & - & \cdot & 0 \\ \cdot & \cdot & \cdot & \cdot \\ - & - & \cdot & 0 \end{pmatrix} \quad (4)$$

Grovfeilen ∇_i estimeres deretter sammen med de ukjente parametrene ved:

$$\hat{x}_i = (A_i^T P A_i)^{-1} A_i^T P l \quad (5)$$

, der $\hat{x}_i^T = (- \quad - \quad \cdot \quad \nabla_i)$

Kofaktormatrisen til de ukjente parametrene Q_{xx} er gitt som:

$$Q_{xx} = (A_i^T P A_i)^{-1} \quad (6)$$

, der grovfeilens kofaktor $q_{\nabla\nabla}$ er det siste elementet på diagonalen i kofaktormatrisen til de ukjente.

$$Q_{xx} = \begin{pmatrix} - & - & \cdot & - \\ - & - & \cdot & - \\ \cdot & \cdot & \cdot & \cdot \\ - & - & \cdot & q_{\nabla\nabla} \end{pmatrix} \quad (7)$$

A posteriori standardavvik på vektsenheten uten innvirkning fra grovfeilen ∇_i estimeres ved:

$$\hat{\sigma}_0^2 = \frac{1}{n - e - 1} (v_i^T P v_i) \quad (8)$$

, der $v_i = A_i \hat{x}_i - l$.

Merk at man får en frihetsgrad mindre fordi man bruker en observasjon til å estimere grovfeilen.

Standardavviket til den estimerte grovfeilen kan nå beregnes som:

$$\hat{\sigma}_{\nabla} = \hat{\sigma}_0 \sqrt{q_{\nabla\nabla}} \quad (9)$$

3 Grovfeilsøk

Hvor stor innvirkning er grovfeil har på resultatet er avhengig av geometrien i systemet og observasjonenes vektor.

Hypotesene ved grovfeilsøk er:

$$H_0 : \nabla_i = 0$$

$$H_1 : \nabla_i \neq 0$$

, der ∇_i er grovfeil i observasjon nr. i .

Teststørrelsen ved multiippel t-test er gitt som:

$$t = \frac{\hat{\nabla}_i}{\hat{\sigma}_{\nabla}} \sim T_{(n-e-1)} \quad (10)$$

Dersom $|t| > T_{(n-e-1, 1-\alpha/2)}$ vil H_0 forkastes og man påstår $\nabla_i \neq 0$, dvs. en sannsynlig grovfeil er *identifisert* i observasjon nr. i.

Observasjonen med størst t-verdi fjernes så fra systemet (*adapsjon*) og grovfeilsøket gjentas til alle observasjonene har passert testen.

4 Indre pålitelighet

Med en observasjons redundans menes hvor stor andel av grovfeilen som vises i observasjonens restfeil. Redundansen til observasjon nr. i er diagonalelementet r_{ii} i matrisen R gitt ved:

$$R = Q_{vv}P \quad (11)$$

$$Q_{vv} = P^{-1} - AQ_{xx}A^T \quad (12)$$

For ukorrelerte observasjoner er $0 < r_{ii} < 1$.

Største gjenværende grovfeil estimeres ved å bruke endepunktene i et konfidensintervall rundt den estimerte grovfeilen. Man velger det endepunktet som har størst tallverdi:

$$\nabla_{max_i} = \max(|\hat{\nabla}_i \pm \hat{\sigma}_{\nabla_i} \times T_{(n-e-1, 1-\alpha/2)}|) \quad (13)$$

Indre pålitelighet forteller altså hvor store grovfeilene kan være med den gitte sannsynlighet for riktig slutning.

5 Ytre pålitelighet

Ytre pålitelighet gir svar på hvor stor skade de gjenværende grovfeilene kan gjøre på de ukjente, f.eks. koordinatene.

$$\nabla_x = (A^T P A)^{-1} A^T P \nabla_{max} \quad (14)$$

, der ∇_x er såkalt punktdeformasjon og $\nabla_{max}^T = (\nabla_{max_i} \ 0 \ 0 \ \dots \ 0)$ er største gjenværende grovfeil i observasjon nr. i.

6 Bonferroni korreksjon

Ved utføring av multiple sammenligninger i ett og samme datasett må signifikansnivået korrigeres for å ta høyde for den økte sannsynlighet for Type-I feil (dvs. sannsynligheten for å forkaste null-hypotesen når den er sann).

Sannsynligheten for *ikke* å gjøre en Type-I feil ved n multiple tester kan skrives som:

$$(1 - \alpha) \cdot (1 - \alpha) \cdot \dots = (1 - \alpha)^n \quad (15)$$

Vi må videre skille mellom to betydninger av signifikansnivået α :

- α_{pt} er sannsynligheten for å gjøre en Type-I feil *per test*.
- α_{pf} er sannsynligheten for å gjøre en Type-I feil *per familie av tester*.

Sannsynligheten for å gjøre minst en Type-I feil for multiple tester kan nå skrives som:

$$\alpha_{pf} = 1 - (1 - \alpha_{pt})^n \quad (16)$$

Motsatt kan dette uttrykkes som:

$$\alpha_{pt} = 1 - (1 - \alpha_{pf})^{1/n} \quad (17)$$

Ofte approksimeres dette uttrykket ved kun den lineære delen av Taylorekkeutviklingen av (17), og kalles da for *Bonferroni* korreksjon.

$$\alpha_{pt} \approx \frac{\alpha_{pf}}{n} \quad (18)$$

7 Konfidensellipser

En konfidensellipse er definert ved at den med en gitt sannsynlighet inneholder er nærmere angitt beregnet punkt. Den avledes normalt fra en feilellipse.

Gitt et estimat på koordinatene $\hat{x}$. Feilellipser tar utgangspunkt i kovariansmatrisen til koordinatene Σ_{xx} :

$$\Sigma_{xx} = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{pmatrix} \quad (19)$$

, der Σ_{xx} er positiv definit slik at den inverse eksisterer.

En statistiker ville skrive $x \sim N_2(0, \Sigma_{xx})$ som betyr at x har en todimensjonal normalfordeling med forventning null og kovarians Σ_{xx} .

Vektoren x ligger med en gitt sannsynlighet innenfor en kurve beskrevet av den kvadratiske formen:

$$x^T \Sigma_{xx}^{-1} x = c^2 \quad (20)$$

Siden Σ_{xx} er positiv definit vil denne kurven være en ellipse.

Egenvektorene til Σ_{xx} diagonaliserer matrisen (og dens inverse):

$$y^T \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}^{-1} y = c^2 \quad (21)$$

$$\frac{y_1^2}{(c\sqrt{\lambda_1})^2} + \frac{y_2^2}{(c\sqrt{\lambda_2})^2} = 1 \quad (22)$$

, der λ_1 og λ_2 er egenverdiene til matrisen Σ_{xx}^{-1} , og $y^T = (y_1 \ y_2)$ er en egenvektor. Dette er feilellipsen.

Ofte setter man $c = \sigma_0$.

Feilellipsens orientering bestemmes fra:

$$y = \begin{pmatrix} \cos \phi \\ \sin \phi \end{pmatrix} \quad (23)$$

, der ϕ er retningsvinkelen til den aktuelle egenvektoren.

Parametrene som beskriver feilellipsen kan beregnes som følger:

$$a = c\sqrt{\lambda_1} \quad (24)$$

$$b = c\sqrt{\lambda_2} \quad (25)$$

$$\phi = \arctan\left(\frac{y_2}{y_1}\right) \quad (26)$$

Parametrene til feilellipsen kan også beregnes direkte fra Σ_{xx} :

$$\lambda_1 = \frac{1}{2}(\sigma_1^2 + \sigma_2^2 + \sqrt{(\sigma_1^2 + \sigma_2^2)^2 - 4(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)}) \quad (27)$$

$$\lambda_2 = \frac{1}{2}(\sigma_1^2 + \sigma_2^2 - \sqrt{(\sigma_1^2 + \sigma_2^2)^2 - 4(\sigma_1^2\sigma_2^2 - \sigma_{12}^2)}) \quad (28)$$

Retningsvinkelen ϕ for ellipsens lange akse er gitt ved:

$$\tan(2\phi) = \frac{2\sigma_{12}}{\sigma_1^2 - \sigma_2^2} \quad (29)$$

Konfidensellipsen finnes så ved å velge en passende verdi for c slik at ellipsen med en gitt sannsynlighet inneholder det aktuelle punktet.

Merk at konfidensellipsen **ikke** direkte vil vise standardavviket i de ulike retningene. Dette er kun tilfelle dersom konfidensellipsen er en sirkel.